

Inteligență Artificială

Lucrare de laborator – Varianta 2

6 iunie 2026

În această lucrare veți antrena modele de regresie pentru determinarea coordonatelor geografice (latitudine și longitudine) asociate unor postări de pe rețelele de socializare, scrise în limba germană.

Setul de date se află în directorul curent și este structurat în următoarele trei fișiere:

- `train_samples.txt` - textele brute destinate etapei de antrenare a modelelor;
- `train_coordinates.npy` - etichetele setului de antrenare (coordonatele geografice reale), folosite ca valori țintă;
- `test_samples.txt` - setul de date de testare, necesar pentru crearea fișierelor de predicții.

Rezolvați următoarele cerințe:

1. **(3p)** Antrenați un model de regresie Ridge. Pentru a obține punctajul acordat, trebuie să implementați corect modelul și să generați un fișier cu predicțiile pe datele de test (conform observațiilor de la final).

1p – Mean Squared Error maxim pe datele de test = 1.10

2p – Mean Squared Error maxim pe datele de test = 0.90

3p – Mean Squared Error maxim pe datele de test = 0.80

2. **(2.5p)** Scrieți o funcție care construiește un vocabular format din cele mai relevante și specifice cuvinte pentru diferitele regiuni geografice din setul de antrenare, utilizând o abordare de tip TF-ISF (Term Frequency - Inverse Spatial Frequency), așa cum este descrisă mai jos.

Funcția trebuie să partiționeze spațiul geografic (definit de coordonatele datelor) într-o grilă de 3x3 subregiuni, toate având aceeași suprafață. Pentru a realiza acest lucru, veți determina mai întâi limitele extreme ale spațiului geografic pentru a genera granițele grilei.

Ulterior, atribuiți fiecare text de antrenare subregiunii corespunzătoare pe baza coordonatelor sale. Concatenați toate textele dintr-o subregiune pentru a forma un singur "super-document" reprezentativ pentru acea zonă. Aplicați o transformare de tip TF-IDF la nivelul întregii hărți pe super-documentele rezultate. Astfel, cuvintele utilizate frecvent peste tot vor fi penalizate, iar termenii specifici unei anumite locații vor primi scoruri mari.

Pentru fiecare subregiune, păstrați cele mai importante 700 de cuvinte pe baza scorurilor obținute (dacă o regiune are mai puține cuvinte le veți păstra pe toate). În

final, reuniți vocabularele regionale obținute și păstrați doar cuvintele unice pentru a forma vocabularul general.

3. **(2.5p)** Folosindu-vă de vocabularul calculat la exercițiul anterior, determinați reprezentarea TF-IDF a exemplelor și antrenați un model SVM folosind un kernel RBF.

1p – Mean Squared Error maxim pe datele de test = 0.90

2p – Mean Squared Error maxim pe datele de test = 0.82

2.5p – Mean Squared Error maxim pe datele de test = 0.75

4. **(2.5p)** Folosiți metoda celor mai apropiați vecini pentru a prezice latitudinea și longitudinea. Determinați cei mai apropiați vecini ai unui exemplu folosind ca funcție de similaritate funcția kernel Hellinger. Funcția de similaritate va fi aplicată pe vectorii rezultați de la exercițiul 3, mai precis reprezentarea TF-IDF.

1p – Mean Squared Error maxim pe datele de test = 1.10

2p – Mean Squared Error maxim pe datele de test = 0.92

2.5p – Mean Squared Error maxim pe datele de test = 0.88

5. **(1.5p)** Creați un raport al experimentelor însoțit de evaluarea pe un set de validare a diferite combinații de hiperparametri pentru modelele de la punctele 1, 3 și 4. Raportul poate conține tabele sau grafice.

1p - Oficiu

Observații importante:

După implementarea cerințelor de mai sus, trebuie să trimiteți într-un folder denumit {Nume}_{Prenume}_{Grupa}_V{Varianta}:

a) Cel mult 1 submisie pentru setul de testare cu metodele de la punctul 1; cel mult 3 submisii pentru setul de testare cu fiecare din metodele de la punctele 3 și 4. O submisie constă într-un fișier .npy denumit:

`{Nume}_{Prenume}_{Grupa}_subiect{i}_solutia_{j}.npy`

unde i este numărul subiectului (1, 3 sau 4) și j este numărul submisiei (1, 2 sau 3), în care se află un tensor ce conține coordonatele pentru toate exemplele de test.

b) Codul aferent pentru antrenarea modelelor și obținerea soluțiilor trimise. Pentru fiecare submisie, codul trebuie organizat într-un singur fișier .py denumit:

`{Nume}_{Prenume}_{Grupa}_subiect{i}_solutia_{j}.py`

unde i este numărul subiectului (1, 2, 3 sau 4) și j este numărul submisiei (1, 2 sau 3).

c) Raportul de la punctul 5.

Folderul cu soluții și cod (fără date sau cerință) se va arhiva în format ZIP, sub denumirea:

{Nume}_{Prenume}_{Grupa}_V{Varianta}.zip

Exemplu:

Denumire director: Popa_Marian_231_V2

Prima submitere pentru subiectul 3: Popa_Marian_subiect3_solutia1.txt

Codul care a generat submiterea de mai sus: Popa_Marian_subiect3_solutia1.py

Denumire arhivă: Popa_Marian_231_V2.zip

După finalizarea examenului, stații de lucru / laptop-ul va rămâne în sală, până la trimiterea soluției pe mail în prezența unui supraveghetor.

Soluțiile se vor trimite la: **fmi.unibuc.ia+test@gmail.com**